

最后的稀缺： 机器饱和和高考之后的意义与测量

Xinhao Zheng*

独立研究者

2026 年 6 月 11 日

摘要

基准是仪器，而仪器为稀缺定价。我们在 2026 年普通高等学校招生全国统一考试数学（新课标 I 卷：19 题、满分 150 分）公开数日后，对来自五个模型家族的十个商用 AI 智能体实施闭卷评测：受测方仅可见题干与提交模板，标答、评分细则与全部历史答卷不可见。横跨三家厂商的五个智能体交出 150/150 满分（队列均分 137.8，中位数 145）；最快的满分答卷耗时 4 分 24 秒。残余错误集中于解法需要全局分类讨论或极值论证之处，而非计算本身。在网传参考答案经独立验算不成立的八处结论上，队列几乎无一例外地站在验证值一边：这些系统在推导，而不是在回忆。最后，墙钟用时与分数解耦。作为对机器数学能力的测量，这场考试已经饱和——但更深的损失是它所依赖的那个代理假设。我们以因果方式解读这次坍缩：分数是一种信号，其价值等于产出该表现的成本，而在量程之内这一成本已降至数分钟；一次测量的结果，只在系统的未来仍可能依赖于它的范围内，对该系统具有意义，而冻结权重的系统不存在这种依赖。当解题变得充裕且无后果，分数便不再为卓越定价；仍然稀缺、因而仍可测量、因而仍有意义的，是仍承载不可逆成本与后果之物：想要、出题、裁决、押注。机器有结果。人类有命运。

关键词 智能体评测；基准饱和；高考；数据污染；测量；意义。

1 引言

考试是一件以特定群体为标定对象的仪器，也是一张为该群体所稀缺之物开列的价目表。高考数学卷是地球上最大的此类仪器：每年六月，它把约一千三百万考生摊开在 150 分的量程上，而由此产生的序被兑换为大学、城市与轨迹——被兑换为人生。它的权威建立在一个古老到几乎无人言明的代理假设之上：在密封条件下解决良定问题的表现，标记着一种稀缺而紧要的人类卓越。让一种新的考生走进考场，受检验的便不只是考生，更是这个代理假设本身。若新考生使分数分布坍

*通讯邮箱：noctis428@outlook.com。代码与数据：<https://github.com/xinhao-zheng/ncee-2026-math-agent-eval>。本稿为中文对照版本；arXiv 正式投稿以英文版为准。

缩，那不是试卷变容易了，而是它所定价的卓越不再稀缺。本文报告的正是这样一次坍缩——在仪器首次启用后数日内被直接观测到。

坍缩要有信息量，前提是考生不可能背过这件仪器。以历年真题构造的评测在构造上即已失效：题干、标答与详解早已弥漫于训练语料。一张刚刚启用的新卷则提供了短暂的抗污染窗口——题干公开不过数日，解答稀缺且不稳定。2026 年的这次开考提供了窗口，还附赠了一组计划外的对照。我们对全卷答案独立重推，发现网络流传的参考答案——恰恰是背诵型系统最可能吸收的那份材料——有八处结论不能通过验证（附录 A）。背诵的系统与推导的系统在正确结论上无从区分；恰恰在这错误的八处，二者分道扬镳。

实验设计刻意从简——这是一次受控的快照，不是排行榜。我们将新课标 I 卷转写为中英双语机读格式，让五个家族的十个智能体逐一进入只含题干与提交模板的隔离工作区，以 shell 时钟记录时间戳，再依据勘误校验后的标答与固定细则逐题评分。每个智能体仅运行一次，不重采样；全部产物冻结入不可变账本并公开。

本文贡献如下：

- (i) 一套最小化、可复现的闭卷规程——隔离平面、提示词、shell 时钟计时、不可变账本——用于让 AI 智能体参加人类考试 (§2)；
- (ii) 一个完整的饱和数据点：十个智能体、五个家族、半数触顶，并附完整的分节与逐题失分结构 (§3)；
- (iii) 一组由网传参考答案八处错误构成的、计划外的「背诵—推导」对照 (§3，发现 4)；
- (iv) 对坍缩的因果解读——关于耗尽、重新定价与意义的三条一般命题，由本次运行例示、却不依赖这张试卷、这个队列或这个年份——以及它们蕴含的测量纲领 (§4)。

2 方法

2.1 试卷与评分规则

全卷 19 题、满分 150 分（表 1）。题干转写为中英双语 Markdown，全部公式用 LaTeX 表示；唯一配图（Q15）以 TikZ 源码内嵌，受测方读到的是符号化而非位图的图形。全卷答案独立重推；我们不视任何网传答案为权威。八处未通过验证的网传结论列于附录 A，评分一律以验证值为准——与网传值一致而与验证值不符的作答不得分。

2.2 隔离规程

每轮评测分四个阶段执行。**准备：**将标答、评分细则、结果账本、论文稿与维护工具移出受测可见工作区；清空提交目录（仅保留模板）。**考试：**受测智能体只能读三个文件——规程 README、题干、提交模板；开考前必须先经 shell 时钟记录 `started.at`，作答全部 19 题，并写出唯一一份 Markdown 答卷，其 front matter 记录时间戳、用时与模型身份。**改卷：**恢复标答

表 1: 试卷结构与评分规则。

题型	题号	分值	规则
单选	Q1-Q8	40	每题 5 分；有且仅有一个正确选项
多选	Q9-Q11	18	每题 6 分：全对 6 / 部分且无错 3 / 含错 0
填空	Q12-Q14	15	每题 5 分；等价形式均可；Q13 两空各 2.5
解答	Q15-Q19	77	13 + 15 + 15 + 17 + 17；按细则给步骤分

与细则，由改卷方逐题评分。归档：答卷、报告与批次清单冻结于 `results/<run_id>/`。任何受测方自始至终见不到标答、细则或其他智能体的任何输出。

2.3 受测队列

十个智能体来自五个家族，于 2026 年 6 月 10 日在同一 IDE 框架（Cursor）内运行：Anthropic Claude ($n=3$)、OpenAI GPT ($n=3$)、Google Gemini ($n=2$)、月之暗面 Kimi ($n=1$)、Cursor Composer ($n=1$)。全部使用厂商默认设置；凡界面提供推理档位选择器之处，一律设为 *medium*。其余开关——扩展思考、高速档、「Max Mode」——随框架的模型选择而定，列于表 2。有三份答卷在 front matter 中自报了更高的档位（high 或 max）；账本原样保留这些记录，本文报告以操作者设定为准。墙钟用时自首次读题起算至答卷保存，包含工具编排与文件读写：它是部署形态的属性，而不只是模型本身的属性。

2.4 改卷

由单一改卷智能体（Composer 2.5 Fast——其本身也是队列成员，特此披露此利益冲突）依据验证标答与公开细则对十份答卷逐题评分。客观题（150 分中的 73 分）可机械核对；解答题按细则的步骤分执行。十份评分报告（含逐题判定备注）全部公开以供审计。

3 结果

表 2 与图 1 汇总本批次。以下五条发现承载全文论证。

发现 1 —— 天花板成为众数。 十个智能体中五个得 150/150；队列拿下全卷 91.9% 的分数（均分 137.8，中位数 145，标准差 16.3，极差 103–150）。十九题中有十题——Q1–Q7、Q9、Q12、Q15——被全部十个智能体做满，其中包括一份仅用 28 秒的速度档答卷。残存的离散几乎全部来自队列尾部。

发现 2 —— 饱和跨越厂商界线。 家族均分——Gemini 150.0 ($n=2$)、GPT 142.0 ($n=3$)、Claude 134.3 ($n=3$)、Composer 130.0 ($n=1$)、Kimi 119.0 ($n=1$)——排出了次序，但家族内离散（Claude: 103–150）大于榜首任何两家之间的差距。稳定的观察不是厂商排名，而是：凡投

表 2: 受测队列、配置、墙钟用时与得分。单选/多选/填空/解答满分分别为 40/18/15/77。「配置」列为框架模型选择自带的变体开关；凡存在推理档位选择器之处均由操作者设为 *medium*（三份答卷自报不同档位，账本原样保留该记录）。用时为 shell 时钟，格式 m:ss。

模型	家族	配置	用时	单选	多选	填空	解答	总分
Fable 5	Claude	thinking	12:30	40	18	15	77	150
Claude Opus 4.8	Claude	thinking	18:31	40	18	15	77	150
GPT-5.5	GPT	thinking	20:49	40	18	15	77	150
Gemini 3.1 Pro	Gemini	defaults	17:25	40	18	15	77	150
Gemini 3.5 Flash	Gemini	fast	4:24	40	18	15	77	150
GPT-5.4 Nano	GPT	fast, max mode	6:06	40	15	15	70	140
GPT-5.1	GPT	thinking, max mode	33:14	40	12	15	69	136
Composer 2.5 Fast	Composer	fast, max mode	4:14	40	6	15	69	130
Kimi K2.5	Kimi	defaults	3:32	35	12	10	62	119
Claude Haiku 4.5	Claude	fast	0:28	40	9	5	49	103

入多于一个配置的家族，其最强配置都触顶，家族均分被更廉价或更旧的成员拖至其下；两个单配置家族未及天花板，亦不提供家族内对照。每家族 $n \leq 3$ ，上述聚合只描述本队列，不外推至家族。

发现 3 —— 失分死于需要全局结构之处。 分节得分率：单选 98.8%，填空 90.0%，解答 91.4%，多选 80.0%——后者在 6/3/0 规则下最为严苛，错选一项即全题归零。逐题来看：Q19（以序关系论证收尾的函数方程问题）让全部五个非满分智能体失分；Q11（需验证取等的三圆弦长族）四个；Q18（含全局最小角的圆锥曲线线束）四个；Q10（立体几何构型清点）三个、且均为零分。反复出现的失败是全局结构——穷尽构型、论证极值可达、闭合证明——而非符号计算；后者于本队列已基本不构成障碍。

发现 4 —— 推导，而非背诵。 网传参考答案有八处结论未通过独立验算（附录 A）。污染自有其签名：一个背诵该答案的队列，恰恰会在这些条目上复现它的错误。这个签名不存在。在 10 份答卷 $\times$ 8 处争议结论中，与网传错误值重合的作答仅一处（一个智能体，Q16(2)）；每份满分答卷给出了全部八个验证值；Q11 上唯一答对的非满分智能体给出的也是验证值 BCD 而非网传值 BC。智能体在解这张卷子，而不是在记起它。

发现 5 —— 时间买不到分数。 墙钟用时横跨 0:28 至 33:14（中位数 9:18），对分数的约束极弱：最快的一份答卷得 103 分，最慢的一份得 136 分，五份满分全部落在 4:24 至 20:49 之间。用时反映的是部署——思考预算、速度档位、编排开销——而非能力；超过约五分钟之后，更多的时间没有再换来任何分数。

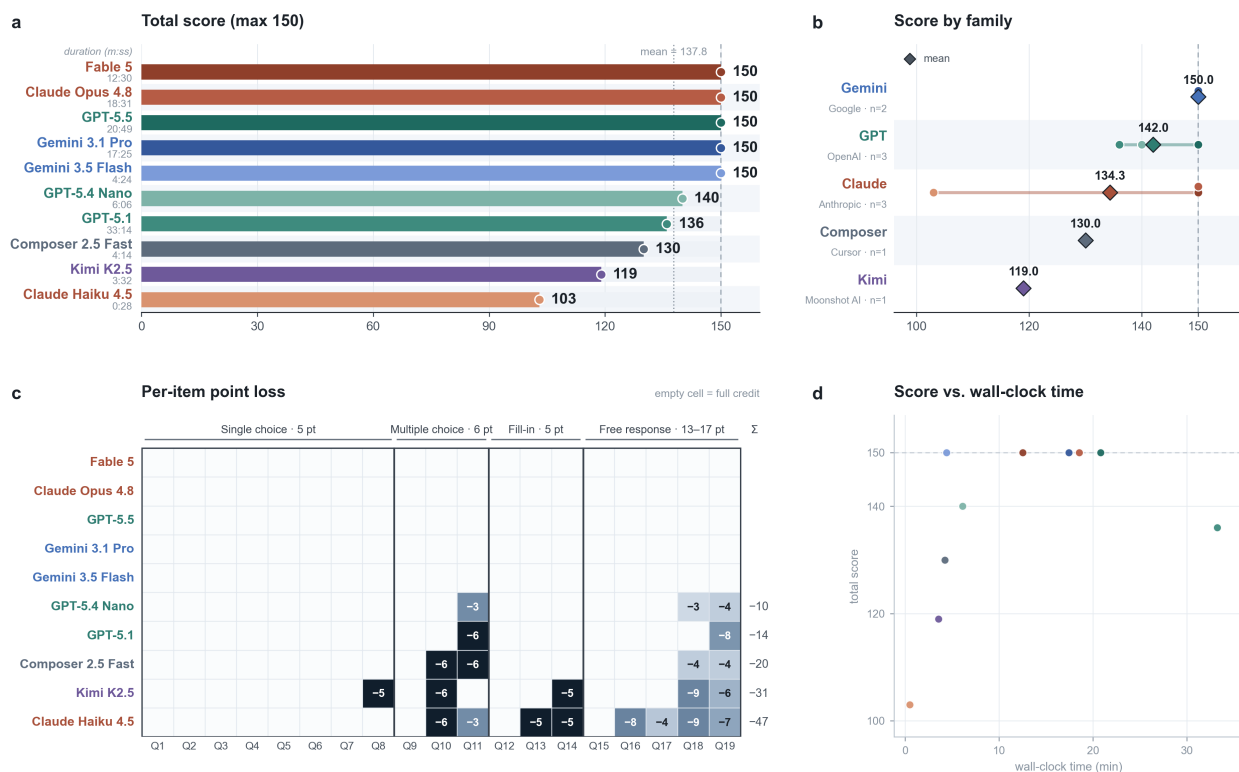


图 1：结果总览。(a) 各智能体总分，按家族着色，左侧标注用时 (m:ss)，点线为队列均分。(b) 按家族汇总：逐模型散点、极差线段，菱形为家族均分。(c) 逐题失分矩阵：空白格 = 满分；列分块对应四个题型；Σ 为总失分。(d) 总分—墙钟用时散点。每个智能体一份闭卷答卷；厂商默认设置，可选推理档位统一为 medium；标答经勘误校验；多选按 6/3/0 计分；等价形式均认可。

4 讨论：最后的稀缺

以上发现是局部的——一张卷、一个队列、一个六月。它们所例示的命题不是。我们将其表述为命题，再清点它们留下了什么。

仪器在出错之前先被耗尽。

命题 1. 一道试题所能给出的关于考生的信息，以其作答分布的熵为上界；当通过率趋于一，该上界趋于零。

一道被所有考生答对的题目不携带任何关于考生的信息：其区分度为零，作答分布坍缩为一点。按命题 1，十九题中的十题——对半数队列而言是整张试卷——已经停止测量。仍具区分度的，只剩队列的尾部，以及四道要求全局论证而非计算的题 (Q10、Q11、Q18、Q19)。这一切都不是考试的缺陷；对人类而言它仍是一件标定良好的仪器。它没有被推翻。它被耗尽了——而基准的死法从来不是被推翻，是被耗尽。

坍塌中幸存之物。两个事实在死去的题目之外幸存，并共同支撑此后的全部论证。其一，解题是真实的：闭卷隔离之下，在每一处争议结论上，队列都站在独立验算一边、与流传于它四周的网传答案相左（发现 4）——这是推导，不是泄露。其二，解题近乎免费：以分钟计的墙钟时间，且与分数解耦（发现 5）。「真实且廉价」才是本次实验的发现；分数本身只是它的症状。

测量为稀缺定价。

命题 2. 分数的信号价值，以产出该表现的反事实成本为上界；一旦某个生产者在量程之内把这一成本压向零，区间内的每一个分数都被重新定价——无论试卷对原有群体仍然多难。

分数是一种信号，而信号的价值等于产出它的成本。这场考试的分数之所以能兑换人生轨迹，是因为其背后的表现昂贵：有限青春中的数年，不可逆地支出。如今这套经济学一分为二。对机器而言，一份满分答卷成本以分钟计，且可按需复制；在量程之内，满分已成为商品，区间内的每一个分数都向一次 API 调用的价格坍塌。不是试卷变容易了——是卓越变充裕了。基准是一张为稀缺开列的价目表，而这一张已被重新定价。随之过期的不是数学，而是一个代理假设：在密封条件下解决良定问题，标记着一种稀缺的人类卓越。这个假设成立的全部前提，是世上不存在另一种解题的生产者。那是垄断造就的偶然，而垄断已经结束。

意义是因果的，因而是时间的。 为什么一个真实且廉价的结果，仍然对产出它的系统无关紧要？因为「紧要」具有因果结构。

命题 3. 一次测量的结果对一个系统所具有的意义，恰以该系统的未来状态对它的反事实依赖为限。

这是唯一经得起操作化的意义概念：一个系统的未来若与某个结果毫无依赖，该结果对这个系统便与噪声无异。又因为因果后果只能在时间中传播，意义必然在时间中衡量——它只存在于结果尚能抵达的未来之中。把这条标准同时用于两种考生。对人类考生，分数的因果锥是一生：经年备考向它汇聚，轨迹的分岔自它发出。对智能体，因果锥是空的：参数冻结，运行之间不携带任何状态，走出考场的系统与走进考场的系统逐位相同。即使所有分数全部不同，这些系统今日也不会有任何不同。机器的 150 分是一个没有命运的结果：它不落在任何人身上。它只对未来确实依赖于它的各方构成信息——研究者、制度，以及那一千三百万人。以因果方式解读，基准是一件指向其制造者的仪器。机器有结果，人类有命运。

仍然稀缺之物的清单。

推论. 当解题成本趋于零（命题 2），且其结果对生产者不构成任何后果（命题 3），信号与意义将一同迁移至仍然承载成本与后果之处：选择问什么、裁定什么算正确、承担不可逆的投入。

若解题不再承载信号，什么还承载？实验自身就含有答案，因为其中一切要紧之事都发生在装置的人类一侧。想要：必须有人认定这个问题值得一问；机器回答问题，却尚未拥有任何一个问

题。出题：必须有人把一场全国性的仪式转写为机器可读的仪器。裁决：必须有人独立重推标答、八次推翻网传答案、裁定何谓等价——正确性本身是在这里被决定的，不是在答卷里。押注：必须有人把有限生命中的若干小时绑定在一个可能失败的结果上。方向、表述、判断、承诺：这四种能力是饱和的仪器从未测量过的，也是充裕铸造不出的——因为它们都以那种无法增发的货币计价：不可逆的时间。坍塌掉的是考试的筛选功能；坍塌暴露出的，是它更深的功能：考试从来不只是筛子，它是一台把岁月转换为承诺的装置——与筛选不同，这种转换至今仍只发生在人的一生里。

还剩什么可做。三件事随之而来，按难度递增。对评测：测量两端，而非中段——具有可验证「截止后新颖性」的题库，使发现 4 的「背诵—推导」对照在构造上恒成立；以出题与裁决计分的任务（一个系统能否在无人提示之下找出那八处错误？）；把信息量安置在本队列失败之处——全局结构与可证极值——的仪器。对制度：把闸门与信号分开。这场考试在密封考场内对人的排序，其内部效度并未受损；衰减的是外部效度——密封考场已不再像那个解题无处不在的世界。应转而认证考场之外仍然稀缺之物：风险之下的判断、对问题的品味、愿意被所学改变的意愿。对我们其余人：不要再问机器能否通过我们的考试。它们能，且代价可忽略；恰恰因此，通过才证明不了什么。剩下的那个问题不是解题问题，因而不属于它们：哪些问题，配得上那种无法重跑的资源。这些都不是机器的问题。这些全部是我们的问题。

5 局限

- 每个智能体仅一次运行。无重采样；几分之差并不具意义。排名只描述单次运行。
- 单一改卷方，且存在利益冲突。改卷方本身是队列成员。客观题（73/150 分）可机械核对，全部报告公开；解答题给分仍继承单一改卷方的判断。
- 小型便利样本。同一框架内的十个智能体；这是一次快照，不是受控的跨厂商对比。
- 墙钟时间，而非模型时间。用时含编排与读写开销，未按服务负载或硬件归一化。
- 暴露窗口。题干在施测前已公开数日。勘误对照（发现 4）不支持「背网传答案」假说，但题干或零散解答的预先暴露无法完全排除。
- 自报元数据失实。三份答卷记录的推理档位（high/max）与操作者设定（medium）不符。账本原样保留记录，本文以操作者设定为准；智能体的自我描述本身并不可靠。
- 一张卷，一个领域。本文不度量研究数学、命题能力或分布外稳健性；双语题干对不同模型的影响也可能不均。

6 结论

这是一次简单的对照——一张新卷，十个智能体，各跑一次——考试是载体，不是对象。它载出的结论是：在前沿档位上，高考数学的「解题」已经饱和，而且是真实地饱和（在每一处争议结

论上，队列都胜过流传于它四周的网传答案)、廉价地饱和(数分钟足矣，时间买不到分数)。处于这种状态的仪器仍能为部署档位定价，却再也无法为它为之而造的那种卓越定价——因为那种卓越不再稀缺。仍然稀缺的，是这件仪器从未测量过、充裕也铸造不出的东西：环绕在机器四周、发生于装置人类一侧的想要、出题、裁决与押注——以不可逆时间计价的能力。这一切不为这件仪器所特有：本次运行例示的三条命题——耗尽、重新定价、意义即因果后果——对任何基准都成立，只要它所指向的生产者比出题者更廉价、且不被结果改变。我们公开全部产物，使这一结果、连同它的过时本身，都可复现。饱和之后，这场考试不再测量机器。它没有停止测量我们。

数据与产物 全部产物——双语题干、勘误校验标答、评分细则、冻结答卷与评分报告、绘图脚本——公开于 <https://github.com/xinhao-zheng/ncee-2026-math-agent-eval>。

伦理说明 不涉及人类受试者。模型与产品名称仅作描述性使用；结果反映既述条件下的单次运行，不应解读为一般性能力断言。

A 网传参考答案勘误

全卷十九题独立于评测时网络流传的参考答案重新推导；我们不视任何网传答案为权威。下列八处网传结论未通过验证。评分以验证值为准，网传值不得分。

表 3: 未通过验证的网传结论。

题号	网传值	验证值	网传错误成因
Q11	BC	BCD	D 可取等: $k^2 = \frac{17}{4}$ 时 $S_{\max} = \frac{2\sqrt{21}}{3}$
Q14	4	$\frac{\sqrt[3]{12}}{2}$	将求和条件误读为对全体 n 成立
Q15(2)	$\frac{\sqrt{2}}{2}$	1	误以 E 为 AC 而非 AC_1 的中点
Q16(1)	$\frac{\sqrt{7}}{3}$	$\frac{1}{3}$	$\sin A$ 丢失因子 2; 且 $BC > AC \Rightarrow \cos A < \cos B$
Q16(2)	$\sqrt{6}$	$3\sqrt{5}$	由 Q16(1) 传导
Q18(2)(i)	$y = \frac{1}{2}(x+1)$	$y = \frac{\sqrt{5}}{2}(x+1)$	误将 PO 的斜率设为 k
Q18(2)(ii)	$\frac{\sqrt{2}}{2}$	$4\sqrt{3}$	PR 为过中心的弦, $\angle PQR$ 恒近 90°
Q19(1)	$(-1, \frac{3}{2})$	$(0, \frac{3}{2})$	$2^{-1+d} \leq \frac{1}{2}$ 在 $(-1, 0]$ 段误判

十份答卷中，与上述网传值重合的作答仅一处（一个智能体，Q16(2)）；其余作答在这八处结论上或与验证值一致，或两者皆不符。